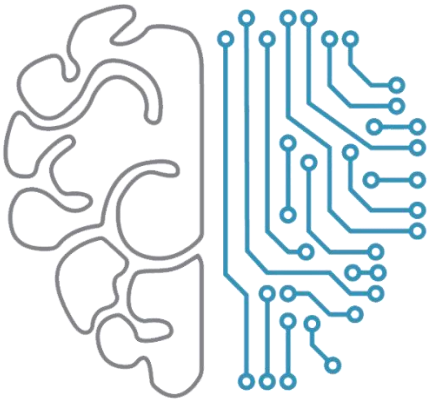
LAPORAN TEORI

STRUKTUR DATA



NAMA : Panji Malik Ibrahim

NIM : 202431202

KELAS : Pembelajaran Mesin (C)

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom

NO.PC :

ASISTEN :

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

1. Exploratory Data Analysis (EDA)

EDA adalah tahap awal untuk memahami karakteristik dan struktur dataset sebelum masuk ke pemodelan. Di langkah ini, data diperiksa mulai dari jumlah baris dan kolom, tipe data tiap variabel, penanganan nilai kosong, hingga perhitungan statistik dasar seperti nilai rata2 dan deviasi standar. Selain itu, visualisasi seperti histogram dan heatmap digunakan untuk melihat sebaran data serta hubungan antarfitur secara lebih visual.

2. Web Scraping

Web scraping merupakan teknik untuk mengambil data secara otomatis langsung dari halaman situs web. Proses ini bekerja dengan cara mengirimkan permintaan http ke peladen web, lalu mengekstrak elemen html atau dom tertentu seperti tabel atau teks. Data acak hasil ekstraksi tersebut kemudian dibersihkan dan diubah ke format terstruktur seperti DataFrame pandas atau csv agar siap diolah.

3. Regresi Linear (Linear Regression)

Regresi linear adalah algoritma supervised learning yang digunakan untuk memprediksi angka kontinu berdasarkan satu atau beberapa variabel bebas. Cara kerjanya adalah mencari garis lurus paling pas yang menghubungkan titik2 data dgn meminimalkan nilai eror atau selisih antara angka prediksi dan nilai aslinya.

4. Decision Tree (Pohon Keputusan)

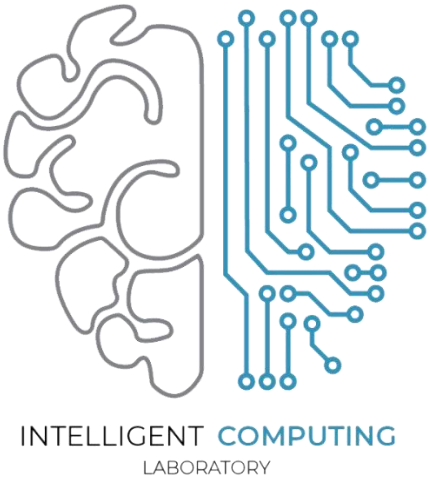
Decision tree adalah algoritma klasifikasi yang membagi data secara bertahap menggunakan struktur bercabang seperti pohon. Pembagian data dimulai dari simpul paling atas root, lalu diturunkan ke simpul cabang berdasarkan syarat nilai fitur tertentu, hingga berakhir di simpul daun. yang menjadi hasil keputusan. Penentuan batas pemisahan di setiap cabang diukur menggunakan tingkat kemurnian data seperti gini impurity.

5. Naïve Bayes (Gaussian Naïve Bayes)

Naïve Bayes merupakan algoritma klasifikasi berbasis statistik yang memanfaatkan teorema bayes. Algoritma ini mengasumsikan bahwa setiap fitur di dalam data bersifat independen atau berdiri sendiri tanpa saling memengaruhi. Untuk data berupa angka kontinu, digunakan varian gasian naive bayes yang mengasumsikan sebaran data mengikuti pola distribusi normal. Hasil prediksi model kemudian dievaluasi menggunakan confusion m,atrik melihat sebaran prediksi benar dan salah. serta classification report mengukur tingkat akurasi, presisi, dan recal.

LAPORAN PRAKTIKUM

STRUKTUR DATA



NAMA : Panji Malik Ibrahim

NIM : 202431202

KELAS : Pembelajaran Mesin (C)

DOSEN : Dr. Efy Yosrita, S.Si., M.Kom

NO.PC :

ASISTEN :

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2025/2026

```python
# Panji Malik Ibrahim_202431202

import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('StudentsPerformance.csv')
df.head()
```

202431202_Panji

	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
0	female	group B	bachelor's degree	standard	none	72	72	74
1	female	group C	some college	standard	completed	69	90	88
2	female	group B	master's degree	standard	none	90	95	93
3	male	group A	associate's degree	free/reduced	none	47	57	44
4	male	group C	some college	standard	none	76	78	75

Gambar 1: Tampilan 5 baris pertama dataset Students Performance.

Penjelasan Gambar 1: Jadi kita mengimpor library pandas dan matplotlib, untuk membaca file StudentsPerformance.csv ke dalam dataframe. Fungsi head() itu bro utk menampilkan 5 sampel baris nomor one data. Terus Hasil keluaran menunjukkan bahwa data berhasil dimuat dengan fitur-fitur demografi siswa.

```python
# Panji Malik Ibrahim_202431202

df.info()
```

202431202_Panji

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 8 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   gender                       1000 non-null   object
 1   race/ethnicity               1000 non-null   object
 2   parental level of education  1000 non-null   object
 3   lunch                        1000 non-null   object
 4   test preparation course      1000 non-null   object
 5   math score                   1000 non-null   int64
 6   reading score                1000 non-null   int64
 7   writing score                1000 non-null   int64
dtypes: int64(3), object(5)
memory usage: 62.6+ KB
```

```python
# Panji Malik Ibrahim_202431202

df.describe()
```

	math score	reading score	writing score
count	1000.00000	1000.000000	1000.000000
mean	66.08900	69.169000	68.054000
std	15.16308	14.600192	15.195657
min	0.00000	17.000000	10.000000
25%	57.00000	59.000000	57.750000
50%	66.00000	70.000000	69.000000
75%	77.00000	79.000000	79.000000
max	100.00000	100.000000	100.000000

Gambar 2: Ringkasan struktur tipe data dan statistik deskriptif

Penjelasan Gambar 2: Untuk Fungsi info() sendiri itu digunakan utntuk mengecek jumlah baris 1.000 data, total 8 kolom, serta jenis tipe data object dan int64. Fungsi describe() menampilkan gambaran statistik nya kita loh mas bro dan data numerik meliputi nilai rata2, standar deviasi, nilai minimum, dan maksimum.

```python
# Panji Malik Ibrahim_202431202

# Imputasi kolom angka dengan mean
for col in df.select_dtypes(include=['int64', 'float64']).columns:
    df[col] = df[col].fillna(df[col].mean())

# Imputasi kolom kategorik dengan modus
for col in df.select_dtypes(include=['object']).columns:
    df[col] = df[col].fillna(df[col].mode()[0])
```

202431202_Panji

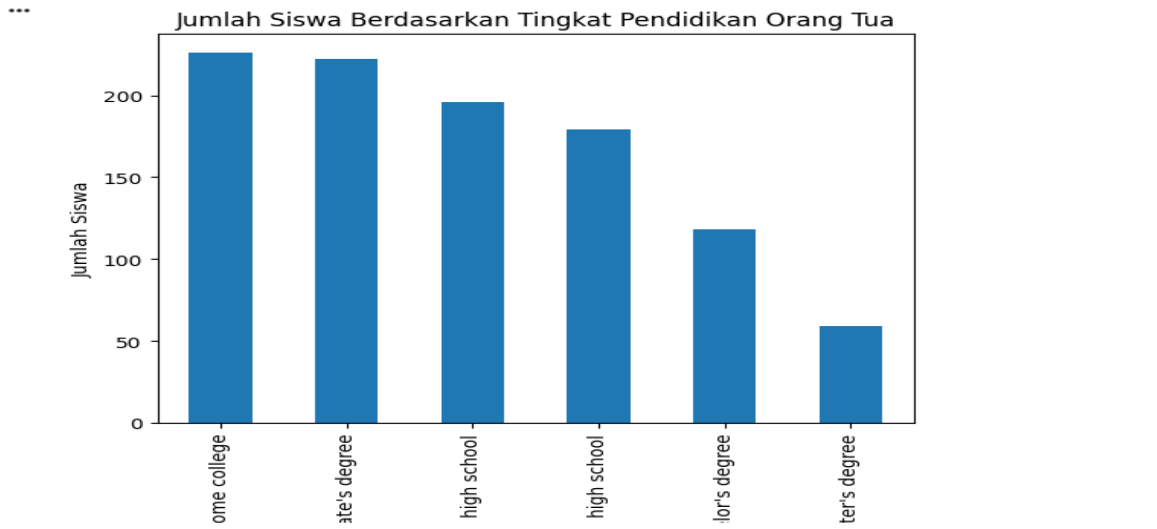
Gambar 3: Kode program imputasi nilai kosong (missing values)..

Penjelasan Gambar 3: Perulangan pertama memeriksa seluruh kolom bertipe angka int64, float64 dan mengisi nilai kosong menggunakan nilai rata2 kolom tersebut. Perulangan kedua memeriksa kolom bertipe kategorik dan mengisi nilai kosong dgn nilai yang paling sering muncul atau disebut modus bro. Seluruh hasil imputasi disimpan kembali ke dalam dataframe.

```
# Panji Malik Ibrahim_202431202

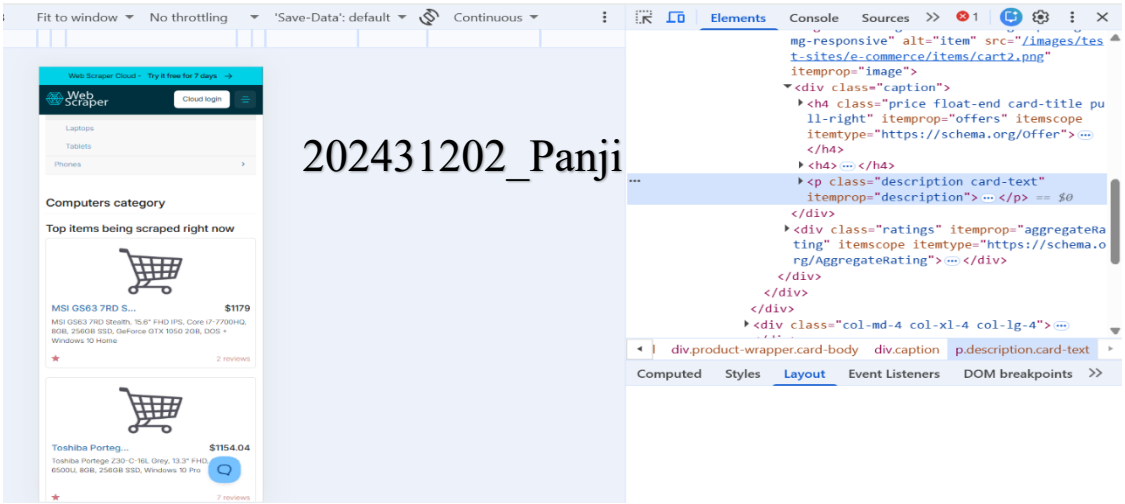
df['parental level of education'].value_counts().plot(kind='bar')
plt.title('Jumlah Siswa Berdasarkan Tingkat Pendidikan Orang Tua')
plt.xlabel('Tingkat Pendidikan Orang Tua')
plt.ylabel('Jumlah Siswa')
plt.show()
```

202431202_Panji



Gambar 4: visualisasi grafik batang tingkat pendidikan orang tua.

Penjelasan Gambar 4: Fungsi value_counts menghitung jumlah frekuensi tiap kategori pada kolom parental level edukasi, lalu divisualisasikan menjadi grafik batang menggunakan plot Judul grafik dan label sumbu diatur menggunakan pustaka matplotlib.



Gambar 5: Hasil Inspect Element pada situs webscraper.io.

Penjelasan Gambar 5: Inspeksi elemen dilakukan untuk menganalisis tag HTML yang menampung data produk ecomerce. Berdasarkan struktur DOM, setiap blok produk dibungkus oleh tag div berkelas product wrapper card body, dengan info harga berada pada tag h4 berkelas price, serta informasi ulasan dan rating tersimpan di dalam tag div berkelas rating.

```
[4]
✓ 2 d

# Panji Malik Ibrahim_202431202

# Scraping data buku dari books.toscrape.com
base_url = "http://books.toscrape.com/catalogue/page-{}.html"
data_buku = []

# Loop halaman 1 sampai 15
for page in range(1, 16):
    url = base_url.format(page)
    res = requests.get(url)

    if res.status_code != 200:
        print(f"Gagal mengakses halaman {page}")
        break

    soup_page = BeautifulSoup(res.text, 'html.parser')
    books = soup_page.find_all('article', class_='product_pod')

    for item in books:
        # 1. Judul Buku
        title = item.h3.a['title']

        # 2. Harga (£)
        price = item.find('p', class_='price_color').text

        # 3. Rating Bintang (One, Two, Three, Four, Five)
        rating_class = item.find('p', class_='star-rating')['class'][1]

        data_buku.append({
```

202431202_Panji

Gambar 6: Kode program perulangan scraping 300 data buku

Penjelasan Gambar 6: Perulangan for page in range itu digunakan untuk menyisir 15 halaman katalog pada situs books.toscrape.com menggunakan requests get. Setiap halaman diparsing dgn BeautifulSoup untuk mengekstrak elemen buku. Program mengambil judul buku dari atribut titel, harga dari class price color, serta rating dari class star rating, lalu menyimpannya ke dalam list data buku.

	A	B	C
1	Judul_Buku	Harga_GBP	Rating_Angka
2	A Light in the Attic	51,77	3
3	Tipping the Velvet	53,74	1
4	Soumission	50,1	1
5	Sharp Objects	47,82	4
6	Sapiens: A Brief History of Humankind	54,23	5
7	The Requiem Red	22,65	1
8	The Dirty Little Secrets of Getting Your Dream Job	33,34	4
9	The Coming Woman: A Novel Based on the Life of the Infamous Femi	17,93	3
10	The Boys in the Boat: Nine Americans and Their Epic Quest for Gold a	22,6	4
11	The Black Maria	52,15	1
12	Starving Hearts (Triangular Trade Trilogy, #1)	13,99	2
13	Shakespeare's Sonnets	20,66	4
14	Set Me Free	17,46	5
15	Scott Pilgrim's Precious Little Life (Scott Pilgrim #1)	52,29	5
16	Rip it Up and Start Again	35,02	5
17	Our Band Could Be Your Life: Scenes from the American Indie Underg	57,25	3
18	Olio	23,88	1
19	Mesaerion: The Best Science Fiction Stories 1800-1849	37,59	1
20	Libertarianism for Beginners	51,33	2
21	It's Only the Himalayas	45,17	2
22	In Her Wake	12,84	1
23	How Music Works	37,32	2

Sheet1

202431202_Panji

Gambar 7: Tampilan data hasil scraping

Penjelasan Gambar 7: Data hasil web scraping dan data cleaning sebanyak 300 baris berhasil di ekspor secara rapi ke dalam berkas Excel. Hasil ekstraksi terbagi sempurna ke dalam 3 kolom, terdiri dari 1 kolom kategori judul buku. serta 2 kolom numerik.

```
[4]
0d
# Panji Malik Ibrahim_202431202

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Baca Dataset hasil scraping
df = pd.read_excel('hasil_scraping_books.xlsx')

print("Dataset berhasil dimuat.")
print("Tampilan 5 data teratas:")
df.head()
```

202431202_Panji

```
Dataset berhasil dimuat.
Tampilan 5 data teratas:
```

	Judul_Buku	Harga_GBP	Rating_Angka
0	A Light in the Attic	51.77	3
1	Tipping the Velvet	53.74	1
2	Soumission	50.10	1
3	Sharp Objects	47.82	4
4	Sapiens: A Brief History of Humankind	54.23	5

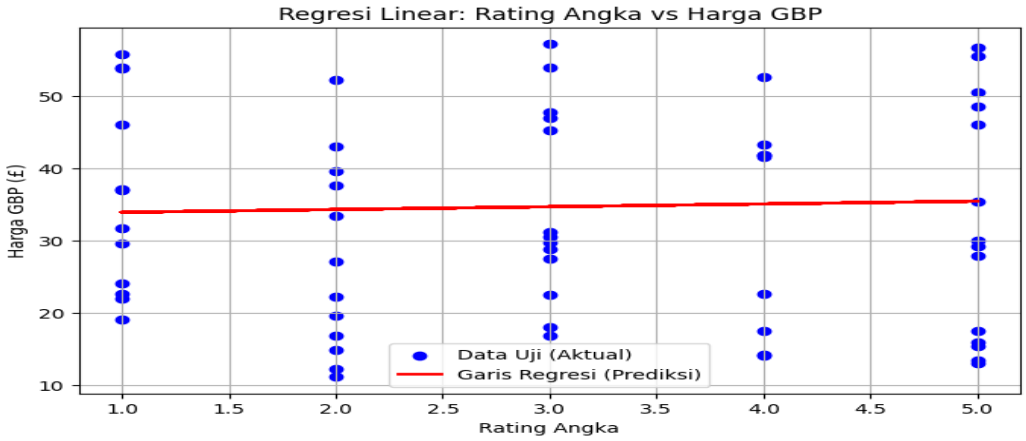
Gambar 8: Import library dan pembacaan dataset

Penjelasan Gambar 8: diawali dengan mengimpor pustaka numpy, pandas, matplotlib, serta pustaka sklearn untuk kebutuhan pemodelan dan evaluasi regresi linear. Berkas dataset hasil_scraping_books.xlsx dibaca menggunakan fungsi pd.read, kemudian fungsi df.head. dipanggil untuk menampilkan 5 baris data teratas guna memastikan dataset berhasil dimuat dengan benar.

```
=== HASIL EVALUASI MODEL REGRESI LINEAR ===
Koefisien (b) : 0.3856
Intercept (a) : 33.5329
MSE           : 204.7155
R2 Score      : -0.0229
==========================================

Persamaan Regresi: Y = 33.5329 + (0.3856) * X
Artinya: Harga_GBP = 33.5329 + (0.3856) * Rating_Angka
```

202431202_Panji



Gambar 9: evaluasi model regresi linear dan visualisasi grafiki.

Penjelasan Gambar 9: Visualisasi grafik memperlihatkan sebaran data uji aktual (titik biru) beserta garis regresi linear garis merah yang menggambarkan hubungan antara rating angka terhadap harga buku dalam GBP.

```
# Panji Malik Ibrahim_202431202

# Import library
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import tree
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import accuracy_score, classification_report

# Baca dataset
df = pd.read_excel('hasil_scraping_books.xlsx')

# Lihat informasi data
print("=== INFORMASI DATASET ===")
df.info()

# Lihat deskripsi statistik
print("\n=== DESKRIPSI STATISTIK ===")
print(df.describe())

# Cek data kosong
print("\n=== CEK DATA KOSONG ===")
print(df.isna().sum())

# Lihat isi unik kolom target (Rating_Angka)
```

202431202_Panji

```
=== INFORMASI DATASET ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 300 entries, 0 to 299
Data columns (total 3 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   Judul_Buku    300 non-null    object
 1   Harga_GBP     300 non-null    float64
 2   Rating_Angka  300 non-null    int64
dtypes: float64(1), int64(1), object(1)
memory usage: 7.2+ KB

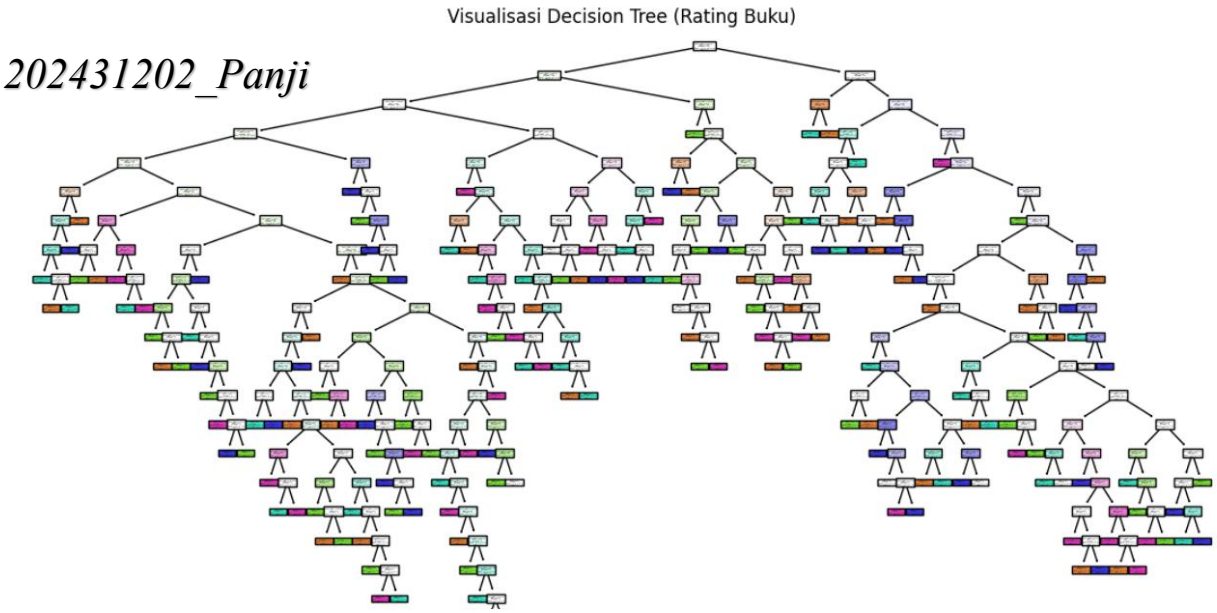
=== DESKRIPSI STATISTIK ===
        Harga_GBP  Rating_Angka
count  300.000000    300.000000
mean    34.262933      2.916667
std     14.102895      1.441057
min     10.160000      1.000000
25%     21.930000      2.000000
50%     35.520000      3.000000
75%     46.022500      4.000000
max     59.640000      5.000000

=== CEK DATA KOSONG ===
Judul_Buku      0
Harga_GBP       0
Rating_Angka    0
dtype: int64

=== ISI UNIK KOLOM TARGET ===
[3 1 4 5 2]
```

Gambar 10:Import library, pembacaan dataset, eksplorasi data.

Penjelasan Gambar 10: Tahap awal diawali dengan mengimpor library yang dibutuhkan, seperti pandas, numpy, matplotlib, serta pustaka pemodelan dan evaluasi *Decision Tree* dari sklearn. Dataset hasil_scraping_books.xlsx dibaca menggunakan fungsi pd.read. Selanjutnya, dilakukan eksplorasi data meliputi pengecekan tipe data dan struktur kolom df.info, statistik deskriptif, serta pemastian tidak adanya data kosong df.isnasum. Pada Langkah 6, dipanggil fungsi rating angka. Unique untuk mengidentifikasi kls unik dari kolom target Rating angka yang bernilai 1 hingga 5, di mana masing-masing angka merepresentasikan tingkatan rating dari bintang 1 (Sangat Buruk) hingga bintang 5 (Sangat Bagus).



Gambar 11: Visualisasi pohon keputusan / plot_tree.

Penjelasan Gambar 11: Visualisasi grafik di atas menampilkan struktur pohon keputusan yg terbentuk menggunakan fungsi plot tree. pohon keputusan ini membagi data secara hirarkisss berdasarkan batas nilai kondisi pada fitur harga GBP untuk mengklasifikasikan buku ke dalam kelas rating angka 1 hingga 5. Setiap simpul node menampilkan keriteria pemisahan, nilai tingkat kemurnian data, jumlah sampel pada simpul tersebut, serta warna simpul yang merepresentasikan prediksi kelas hasil pembagian data.

```
# Panji Malik Ibrahim_202431202

# Prediksi seluruh data uji untuk evaluasi
y_pred = model_dt.predict(X_test)

# Hitung akurasi
akurasi = accuracy_score(y_test, y_pred)
print("=== HASIL AKURASI ===")
print(f"Akurasi Model: {akurasi:.4f} ({akurasi * 100:.2f}%)")

# Tampilkan classification_report
print("\n=== CLASSIFICATION REPORT ===")
print(classification_report(y_test, y_pred))
```

202431202_Panji

```
=== HASIL AKURASI ===
Akurasi Model: 0.2333 (23.33%)

=== CLASSIFICATION REPORT ===
              precision    recall  f1-score   support

           1       0.29      0.20      0.24        20
           2       0.18      0.22      0.20        18
           3       0.25      0.24      0.24        17
           4       0.24      0.29      0.26        14
           5       0.24      0.24      0.24        21

    accuracy                           0.23        90
   macro avg       0.24      0.24      0.23        90
weighted avg       0.24      0.23      0.23        90
```

Gambar 12: Evaluasi akurasi dan classification report model Decision Tree.

Penjelasan Gambar 12: Evaluasi model dilakukan dengan memprediksi data uji x test berjumlah 90 sampel data. Hasil evaluasi menunjukkan nilai akurasi sebesar 23,33%. Rincian performa klasifikasi untuk setiap kelas rating 1 hingga 5 ditampilkan pada tabel classification report,

```
# Panji Malik Ibrahim_202431202
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split

# Ubah fitur kategorikal menjadi angka dengan LabelEncoder
df_encoded = df.copy()
le = LabelEncoder()

for col in fitur_kategorikal:
    df_encoded[col] = le.fit_transform(df_encoded[col])

print("=== DATA PERTAMA SETELAH ENCODING ===")
print(df_encoded.head())

# pisahkan fitur X dan target y
X = df_encoded.drop(columns=['target'])
y = df_encoded['target']

print("\n=== PEMISAHAN FITUR X DAN TARGET Y ===")
print(f"Bentuk/Ukuran X : {X.shape}")
print(f"Bentuk/Ukuran y : {y.shape}")

# Bagi data latih dan uji
X_train, X_test, y_train, y_test = train_test_split(X, y,
```

```
=== DATA PERTAMA SETELAH ENCODING ===
   age  sex  cp  trestbps  chol  fbs  restecg  thalach  exang  oldpeak  slope
0   52    1   0       125   212    0        1      168      0      1.0      2
1   53    1   0       140   203    1        0      155      1      3.1      0
2   70    1   0       145   174    0        1      125      1      2.6      0
3   61    1   0       148   203    0        1      161      0      0.0      2
4   62    0   0       138   294    1        1      106      0      1.9      1

   ca  thal  target
0   2     3       0
1   0     3       0
2   0     3       0
3   1     3       0
4   3     2       0

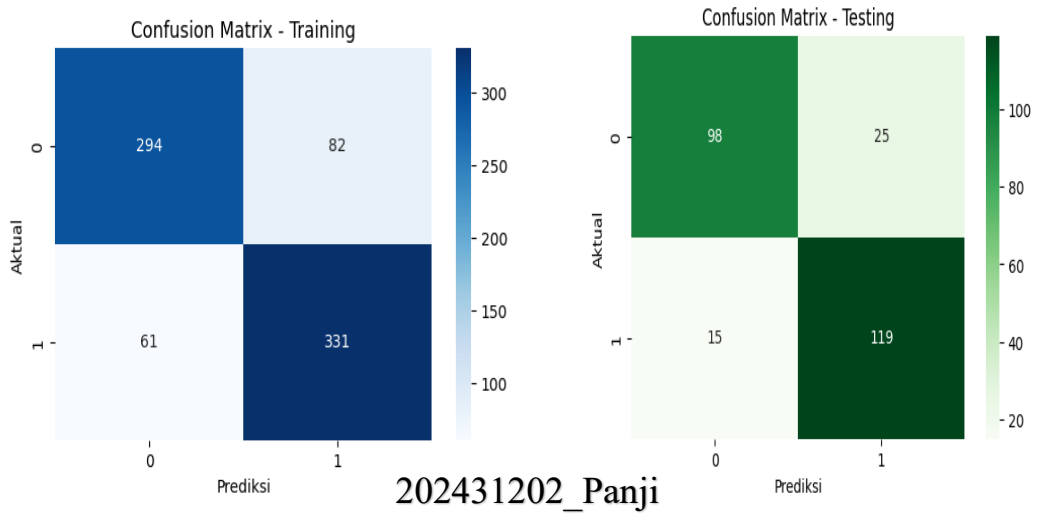
=== PEMISAHAN FITUR X DAN TARGET Y ===
Bentuk/Ukuran X : (1025, 13)
Bentuk/Ukuran y : (1025,)

=== PEMBAGIAN DATA LATIH & UJI ===
Jumlah Data Latih (X_train) : 768 baris
Jumlah Data Uji (X_test)   : 257 baris
```

202431202_Panji

Gambar 13: Transformasi Label Encoding

Penjelasan Gambar 13: keluaran di atas menampilkan proses pemrosesan data pada Heart Disease Dataset. Tahap awal dilakukan dengan label encoding untuk memastikan seluruh variabel berada dalam format numerik yang siap diproses oleh model. Selanjutnya, dataset dipisahkan menjadi variabel independen X sebanyak 13 kolom fitur dan variabel target y. Menggunakan fungsi train test split dengan parameter testsize.



Gambar 14: Visualisasi Heatmap Confusion Matrix Evaluasi Model

Penjelasan Gambar 14: Visualisasi heatmap confusion matrik di atas menunjukkan performa klasifikasi model Gaussian Nakiye Bayes pada Heart Disease Dataset. Pada data latih 768 sampel, model berhasil memprediksi dengan benar 294 data kelas 0 dan 331 data kelas 1. Pada data uji 257 sampel, model berhasil memprediksi dengan benar 98 data kelas 0 dan 119 data kelas 1. Hasil ini membuktikan model memiliki akurasi yang baik dan konsisten tanpa mengalami overfitting.

```
# Panji Malik Ibrahim_202431202

# Uji dengan 1 data baru
data_baru = pd.DataFrame([{
    'age': 55,
    'sex': 1,
    'cp': 2,
    'trestbps': 130,
    'chol': 250,
    'fbs': 0,
    'restecg': 1,
    'thalach': 150,
    'exang': 0,
    'oldpeak': 1.5,
    'slope': 1,
    'ca': 0,
    'thal': 2
}])

# Melakukan prediksi dengan model GaussianNB
prediksi_kode = model_nb.predict(data_baru)

# Mapping kode angka hasil prediksi ke keterangan teks
label_map = {0: 'Tidak Ada Penyakit Jantung', 1: 'Ada Indikasi Penyakit Jantung'}
hasil_prediksi_label = label_map[prediksi_kode[0]]

print("=== HASIL PREDIKSI 1 DATA BARU ===")
print("Data Baru yang Diuji:")
print(data_baru)
print(f"\nHasil Prediksi Target: {hasil_prediksi_label} (Kode: {prediksi_kode[0]})")
```

202431202_Panji

```
=== HASIL PREDIKSI 1 DATA BARU ===
Data Baru yang Diuji:
   age  sex  cp  trestbps  chol  fbs  restecg  thalach  exang  oldpeak  slope  \
0   55    1   2       130   250    0        1      150      0      1.5      1

   ca  thal
0   0     2

Hasil Prediksi Target: Ada Indikasi Penyakit Jantung (Kode: 1)
```

Gambar 15: Pengujian Prediksi 1 Sampel Data Medis

Penjelasan Gambar 15: keluaran di atas menampilkan pengujian inferensi model Gaussian naiye bayes terhadap 1 sampel data medis baru. Sampel data di input dalam bentuk DataFrame berisi 13 fitur medis. Melalui fungsi model nb.predict, model menghasilkan kode prediksi 1 yang dipetakan ke teks "Ada Indikasi Penyakit Jantung", membuktikan model berhasil mengklasifikasikan data baru secara realtime.